

Operációkutatás

6. előadás

Benedek Márton

2026. május 11.

marton.benedek@uni-corvinus.hu

1. Klasszikus hálózati centralitási mutatók

2. PageRank

Egyszerűsített PageRank

Az egyszerűsített PageRank korlátai

A PageRank kiszámítása

3. További leíró statisztikák

4. Hálózati terjedési modellek

Klasszikus hálózati centralitási mutatók

Hálózati központok azonosítása

Kik a legfontosabb egyének a közösségben? A válasz részben attól függ mit értünk fontosság alatt. Például nem feltétlenül ugyanaz a válasz, ha a legnagyobb befolyású, vagy a legközpontibb helyen szereplő egyéneket keressük.

- Hálózati központok azonosításának fontos alkalmazásai vannak a szociológiától kezdve számos tudományágon át a számítástudományig.
- Sokféle módszert fejlesztettek ki egymással párhuzamosan a csomópontok fontosságának mérésére.
- A leggyakrabban használt eljárások a központisági mértékek (centrality measures).
- Ezek a mértékek segíthetnek abban, hogy egyes csoportokat (pl. véleményvezérek, szakértők) azonosítsunk.


A legismertebb központisági mértékek

- Fokszám-központiság (Degree centrality)
- Közelség-mérték (Closeness centrality)
- Közöttiség-mérték (Betweenness centrality)
- PageRank algoritmus

Fokszám-központiság

Egy csúcs fokszám-központisága, nem más, mint a csúcs fokszáma osztva $n - 1$ -gyel (itt $n = |V|$ a gráf csúcsainak a száma). Ez az egyszerű mérték azt feltételezi, hogy a magasabb fokszám önmagában jól jelzi, hogy mennyire központi szerepet tölt be egy csúcs a hálózatban.


Tekintsük a következő példát!



Fokszám-központiság

Egy csúcs fokszám-központisége, nem más, mint a csúcs fokszáma osztva $n - 1$ -gyel (itt $n = |V|$ a gráf csúcsainak a száma). Ez az egyszerű mérték azt feltételezi, hogy a magasabb fokszám önmagában jól jelzi, hogy mennyire központi szerepet tölt be egy csúcs a hálózatban.


A **b** csúcs fokszám-központisége: $c^{deg}(\mathbf{b}) = 2/5$.



Fokszám-központiság

Egy csúcs fokszám-központisége, nem más, mint a csúcs fokszáma osztva $n - 1$ -gyel (itt $n = |V|$ a gráf csúcsainak a száma). Ez az egyszerű mérték azt feltételezi, hogy a magasabb fokszám önmagában jól jelzi, hogy mennyire központi szerepet tölt be egy csúcs a hálózatban.


A **c** csúcs fokszám-központisége: $c^{deg}(\mathbf{c}) = 3/5$.



Fokszám-központiság

Egy csúcs fokszám-központiséga, nem más, mint a csúcs fokszáma osztva $n - 1$ -gyel (itt $n = |V|$ a gráf csúcsainak a száma). Ez az egyszerű mérték azt feltételezi, hogy a magasabb fokszám önmagában jól jelzi, hogy mennyire központi szerepet tölt be egy csúcs a hálózatban.


Írányított gráfoknál külön befok- és kifok-központiségot definiálunk.



Közelség-mérték

Két csúcs távolságát a köztük lévő legrövidebb (irányított) út hosszával definiáljuk. Azt, hogy egy csúcs mennyire periferiális, jellemezhetjük a többi csúcstól vett távolságai összegével. A közelség-mérték ennek a számnak a reciproka. Hasonlóan az előzőhöz itt is szokás $n - 1$ -gyel normálni.


Tekintsük újra az előző példát!



Közelség-mérték

Két csúcs távolságát a köztük lévő legrövidebb (irányított) út hosszával definiáljuk. Azt, hogy egy csúcs mennyire periferiális, jellemezhetjük a többi csúcstól vett távolságai összegével. A közelség-mérték ennek a számnak a reciproka. Hasonlóan az előzőhöz itt is szokás $n - 1$ -gyel normálni.

$$c^{cls}(\mathbf{a}) = \frac{6-1}{1+2+3+4+3} = \frac{5}{13} \quad c^{cls}(\mathbf{c}) = \frac{6-1}{2+1+1+2+1} = \frac{5}{7}.$$



- Képlet szerint a közelség mérték: $c^{cls}(\mathbf{v}) = \frac{n-1}{\sum_{\mathbf{u} \in V} d(\mathbf{u}, \mathbf{v})}$, ahol $d(\mathbf{u}, \mathbf{v})$ az $\mathbf{u}$ és $\mathbf{v}$ csúcsok távolságát jelöli.
- A közelség-mértéket az információ-terjedésének mérőszámaként is felfoghatjuk.
- Az normalizálásra ($n - 1$ -gyel való beszorzásra) azért van szükség, hogy különböző méretű gráfok csúcsainak közelség-mértékét össze tudjuk hasonlítani.
- Ha a gráf nem erősen összefüggő (azaz ha nem lehet minden csúcsból minden más csúcsba eljutni), akkor a képletben ∞ -nel osztanánk, ezt több módon is orvosolhatjuk:
 - nem vesszük figyelembe a nem összekötött csúcsokat (torzít);
 - a nem összekötött csúcsok távolságát n -nek definiáljuk;
 - a szummát és a reciprokot felcseréljük, az $1/\infty$ -t pedig 0-nak definiáljuk (Harmonikus-központiség).

Közöttség-mérték

Közöttség-mérték azt méri milyen gyakran szerepel egy csúcs két másik csúcs közötti legrövidebb úton. Formálisan a következő módon lehet kiszámolni.


- Vegyünk egy $\mathbf{v} \in V$ csúcst. Egy $\mathbf{s}, \mathbf{t} \in V \setminus \{\mathbf{v}\}$ csúcspárra, számoljuk össze, hogy $\mathbf{s}$ és $\mathbf{t}$ között hány legrövidebb út található.
- Számoljuk össze, hogy ezek közül $\mathbf{v}$ hányon szerepel, majd vegyük a két érték hányadosát.
- Összegezzük ezeket a hányadosokat minden $\mathbf{s}, \mathbf{t} \in V \setminus \{\mathbf{v}\}$ csúcspárra.

$$c^{btw}(\mathbf{v}) = \sum_{\mathbf{s} \neq \mathbf{v} \neq \mathbf{t} \in V} \frac{\sigma_{(\mathbf{s}, \mathbf{t})}(\mathbf{v})}{\sigma_{(\mathbf{s}, \mathbf{t})}}$$


ahol $\sigma_{(\mathbf{s}, \mathbf{t})}$ az $\mathbf{s}, \mathbf{t}$ közötti legrövidebb utak száma, $\sigma_{(\mathbf{s}, \mathbf{t})}(\mathbf{v})$ pedig az olyan $\mathbf{s}, \mathbf{t}$ legrövidebb utak száma amelyeken $\mathbf{v}$ szerepel.

- Hasonlóan az előbbiekhez a közöttség-mértéket is normalizálni szokták. Irányítatlan esetben az értékeket $(n-1)(n-2)/2$ hányadossal osztjuk (ennyiféle képpen lehet kiválasztani két csúcsot $n-1$ -ből). Irányított esetben az előbbi kétszeresével $(n-1)(n-2)$ -vel osztunk.
- A közöttség-mérték azt méri, hogy egyes csúcsok mennyire töltenek be híd-szerepet a hálózatban.



Egy birodalmi csillagromboló kapitányaként egy lázadó CR90 korvett osztályú csatahajót üldözünk. Hová összpontosítsuk a tűzerőnket?





Egy birodalmi csillagromboló kapitányaként egy lázadó CR90 korvett osztályú csatahajót üldözünk. Hová összpontosítsuk a tűzerőnket?



A korvett sematikus rajza



A legjobb centralitás értékek



PageRank

- A PageRank algoritmust Larry Page és Sergey Brin (a Google alapítói) fejlesztették ki 1998-ban a Stanfordon. Eredetileg weboldalak rangsorolására tervezték (PageRank a Google keresőmotorjának a legfontosabb komponense), de azóta sok más területen is alkalmazzák.
- A világháló modellezhető egy nagy gráffal, ahol a weboldalaknak csúcsok felelnek meg, a linkeknek pedig a gráf élei. Minden alkalommal, amikor beírunk valamit a Google keresőjébe, arra kérjük a keresőmotort, hogy rangsorolja a honlapokat valamilyen szempont alapján.
- A PageRank alapötlete a következő: *egy weboldal akkor fontos, ha más fontos honlapok linkelik.*

Egyszerűsített PageRank




A PageRank egyszerűsített verziója a következő lépésekből áll:

1. Egy n csúcsú gráfon legyen minden csúcs kezdeti PageRank értéke $1/n$.
2. Frissítsük az értékeket a következő módon: minden $v \in V$ csúcs a kimenő élei mentén egyenletesen szétosztja a PageRank értékét. Ha nincs kimenő éle akkor megőrzi.
3. Iteráljuk a második lépést, amíg a változás elhanyagolható nem lesz.

Figyeljük meg, hogy


- A csúcsok súlyainak összege 1 és ez nem változik az iteráció során.
- Néhány degenerált esetet leszámítva a PageRank értékek konvergálnak, ahogy a lépések száma tart a végtelenhez.

Egyszerű PageRank - egy példa



Az egyszerűsített PageRank verzió kezdeti konfigurációja és az első iteráció.

Egyszerű PageRank - egy példa





A PageRank értékek a $(\frac{1}{5}, \frac{2}{5}, \frac{2}{5})$ vektorhoz konvergálnak. Figyeljük meg, hogy ha az egyensúlyi értékekkel indulunk, akkor az iteráció után visszkapjuk őket.

Tegyük fel, hogy véletlen sétát teszünk a világhálón.


- A kiindulásnál véletlenszerűen, egyenlő valószínűséggel választunk egy csúcsot.
- Az aktuális csúcsból, megint csak véletlenszerűen, egyenlő valószínűséggel választunk egy kimenő élt, és továbbhaladunk rajta. Ha nincs ilyen, akkor egy helyben maradunk
- A valószínűsége, hogy a k . lépés után a $\mathbf{v}$ csúcsban tartózkodunk a $\mathbf{v}$ súlyával egyezik meg, amit úgy kaptunk, hogy k lépést megtettünk az egyszerűsített PageRank algoritmussal.

Az egyszerűsített PageRank korlátai I.



Kezdő és végállapota az egyszerűsített PageRank-nek. A bal alsó csúcs minden PageRank értéket elnyelt.

Az egyszerűsített PageRank korlátai II.



A jobboldali komponens minden PageRank értéket elnyelt.

- Nyelők: kezdjük újra a véletlen sétát
- Kimenő élek nélküli részgráfok: párologtatás


Egy ökológiából vett ötletet használunk fel. Nézzük a víz körforgásának egyszerűsített modelljét. A folyók azért nem száradnak ki, mert a tenger párolog, a párából esőfelhők keletkeznek, amik csapadékot visznek a hegyekbe, a folyók vízgyűjtő területeire. Itt most a PageRank értékek fognak lassan párologni.

- Válasszunk egy $0 < s < 1$ **párolgási faktort**.
- Minden iteráció után szorozzuk meg a csúcsok PageRank értékeit s -sel.
- Az össz-PageRank érték így lecsökkent 1 -ről s -re.
- Az elpárolgott $1 - s$ mennyiséget osszuk szét egyenletesen a csúcsok között.

A gyakorlatban a párolgási faktort 0.7 és 0.9 között szokták megadni. Magas s érték esetén a konvergencia lassabb, viszont a PageRank értékek jobban reprezentálják a hálózati struktúrát.


Átmeneti mátrix

Az átmeneti mátrix azt mutatja meg, hogy mekkora valószínűséggel kerülünk át az egyik csúcsból a másikba.




$$M = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1/3 & 1/3 & 0 & 1/3 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

Annak a valószínűségét, hogy egy adott csúcsban tartózkodunk k lépés megtétele után, az átmeneti mátrix k . hatványa adja meg.




$$M^2 = \begin{pmatrix} 0 & 0 & 1/2 & 1/2 & 0 \\ 1/2 & 1/6 & 0 & 1/6 & 1/6 \\ 0 & 1 & 0 & 0 & 0 \\ 1/3 & 0 & 1/6 & 1/6 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

Javítási ötlet I.




$$M = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1/3 & 1/3 & 0 & 1/3 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

Az **e** csúcs egy nyelő, ha ide jutunk újratekzdjük a véletlen sétát.




$$\hat{M} = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1/3 & 1/3 & 0 & 1/3 \\ 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \end{pmatrix}$$

Javítási ötlet II.



$$\hat{M} = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1/3 & 1/3 & 0 & 1/3 \\ 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \end{pmatrix}$$

Rögzítsük a párolgási faktort: $s = 0.8$. Ekkor minden iteráció után $0.2 = 1/5$ része a PageRank értékeknek elpárolog, és egyenletesen eloszlik az öt csúcs között.



$$\tilde{M} = \begin{pmatrix} 1/25 & 21/25 & 1/25 & 1/25 & 1/25 \\ 1/25 & 1/25 & 11/25 & 11/25 & 1/25 \\ 21/25 & 1/25 & 1/25 & 1/25 & 1/25 \\ 3/75 & 23/75 & 23/75 & 3/75 & 23/75 \\ 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \end{pmatrix}$$

Mátrixtranszformációk

- Legyen M az $n \times n$ -es átmeneti mátrix.
- Legyen $\underline{e}_n$ egy csupa 1-esből álló n hosszú oszlopvektor.
- Jelölje $0 < s < 1$ a párolgási faktort.
- Jelölje $\underline{d}^M$ azt az oszlopvektort, ami jelzi, hogy az M mátrix melyik sora áll csupa 0-ból. Másképpen

$$d_i^M = \begin{cases} 1 & \text{ha az } i. \text{ sora } M\text{-nek csupa } 0 \\ 0 & \text{egyébként} \end{cases}$$

$$\hat{M} = M + \frac{1}{n} \underline{d}^M \cdot \underline{e}_n^\top$$

$$\tilde{M} = s\hat{M} + \frac{(1-s)}{n} \underline{e}_n \cdot \underline{e}_n^\top$$

Definíció

A PageRank az $\tilde{M}^T$ mátrix domináns sajátértékéhez tartozó sajátvektor.

- A PageRank értékek (a sajátvektor komponensei) annak a valószínűségét fejezik ki, hogy egy véletlen sétát tevő ember a hálózat egy adott csúcsán köt ki.
- A Perron-Frobenius tételből következik, hogy $\tilde{M}^T$ domináns sajátértéke mindig 1 és a kapcsolódó sajátvektor (skalárszorozótól eltekintve) egyértelmű.
- Valójában nincs szükség $\tilde{M}$ transzponáltját venni. Számolhatnánk a $\tilde{M}$ domináns sajátértékéhez tartozó baloldali sajátvektorával is.
- Mivel a világhalót leíró mátrix nagy és ritka (sok nullát tartalmaz), és mivel Googlenak másodpercenként több 10 000 keresést kell lebonyolítania, egy gyors módszerre van szükségünk, amely megadja a mátrix sajátvektorát.

Hatványmódszer (Power Method)

A hatványmódszer akkor alkalmazható, amikor az A mátrixnak létezik egy domináns sajátértéke, azaz a sajátértékek sorba rendezhetőek az alábbi módon: $\lambda_1 > \lambda_2 \geq \lambda_3 \geq \dots \geq \lambda_n$.

1. Rögzítsünk egy ε precíziós konstansot.
2. Legyen $\underline{x}_0 = \frac{1}{n}\underline{e}_n$.
3. $k = 1, 2, \dots$ -re, legyen $\underline{x}_{k+1} = A\underline{x}_k$.
4. Álljunk meg, ha $\|\underline{x}_{k+1} - \underline{x}_k\| < \varepsilon$.

Alternatív kiszámítás (Gauss elimináció)

Definíció szerint a λ sajátértékhez tartozó $\underline{x}$ sajátvektor kielégíti az alábbi egyenletet.


$$A\underline{x} = \lambda\underline{x}$$

$\tilde{M}$ esetében tudjuk, hogy domináns sajátértéke 1.

$$\tilde{M}\underline{x} = \underline{x}$$

Hozzávéve, hogy $\underline{x}$ komponenseinek (a PageRank értékeknek) az összege 1, fel tudunk írni egy egyenletrendszert.

Alternatív kiszámítás (Gauss elimináció)



$$\tilde{M} = \begin{pmatrix} 1/25 & 21/25 & 1/25 & 1/25 & 1/25 \\ 1/25 & 1/25 & 11/25 & 11/25 & 1/25 \\ 21/25 & 1/25 & 1/25 & 1/25 & 1/25 \\ 3/75 & 23/75 & 23/75 & 3/75 & 23/75 \\ 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \end{pmatrix}$$

$$a = \frac{1}{25}a + \frac{1}{25}b + \frac{21}{25}c + \frac{3}{75}d + \frac{1}{5}e$$

$$b = \frac{21}{25}a + \frac{1}{25}b + \frac{1}{25}c + \frac{23}{25}d + \frac{1}{5}e$$

$$c = \frac{1}{25}a + \frac{11}{25}b + \frac{1}{25}c + \frac{23}{25}d + \frac{1}{5}e$$

$$d = \frac{1}{25}a + \frac{11}{25}b + \frac{1}{25}c + \frac{3}{75}d + \frac{1}{5}e$$

$$e = \frac{1}{25}a + \frac{1}{25}b + \frac{1}{25}c + \frac{23}{75}d + \frac{1}{5}e$$

$$1 = a + b + c + d + e$$

További leíró statisztikák

Definíció

Egy G gráf összefüggő, maximális részgráfját komponensnek nevezzük.

A gyakorlatban gyakran előfordul, hogy a vizsgált hálózat nem összefüggő. Például egy általános iskolai osztály barátsági hálózata állhat több komponensből, ha a fiúk-lányok külön barátkoznak. A NetworkX modulnak van beépített függvénye ennek kiszámolására.

`number_connected_components(G)`

Definíció

Egy v csúcs klaszterezettségi együtthatója megmutatja, hogy a csúcson keresztül behúzható háromszögek hányad részén szerepel v .

A klaszterezettség lényegében azt mutatja meg, hogy mekkora az esélye, hogy a v csúcs két ismerőse egymást is ismerik. Minél nagyobb a klaszterezettség annál összefonódottabb, közösségibb jellegű egy hálózat. Pl. egy hat csúcsú csillag gráf minden csúcsának a klaszterezettsége nulla, hiszen a gráfon nincsenek háromszögek. Ha behúzunk egy további élt, akkor a központi csúcs klaszterezettsége $\frac{1}{10}$ lesz, mivel a központi csúcs öt barátja között tíz féle képpen tudunk háromszögeket berajzolni, de ezek közül csak egy létezik.

```
clustering(G, nodes=None, weight=None)
average_clustering(G, nodes=None, weight=None,
count_zeros=True)
```


Definíció

Egy v excentrikussága egyenlő a tőle legtávolabbi csúctól való távolságával. A G gráf átmérője a benne lévő csúcsok excentrikusság értékeinek legnagyobbika, a sugár pedig ezek legkisebbike.

Pl. ha a G gráf egy öt csúcsból álló út, akkor átmérője négy hosszúságú, míg a sugara kettő.

```
radius(G, e=None, usebounds=False, weight=None)
diameter(G, e=None, usebounds=False, weight=None)
```

Ismert gondolkísérlet, hogy hány kézfogásra vagyunk egy híres embertől, pl. az USA elnökétől. Egy gráfon ezt a legrövidebb utak átlagos hosszával tudjuk megmérni. A közösségi hálózatokon meglepően kis érték (5 és 8 között) szokott kijönni erre a számra. Ismerek valakit, aki ismer egy az amerikai nagykövetségen dolgozó embert. Ez a dolgozó biztosan kezet fogott már a nagykövettel, aki pedig a kinevezésekor kezet fogott az amerikai elnökkel.

```
average_shortest_path_length(G, weight=None, method=None)
```

- A hálózati központisági mértékek modell-specifikusak. Mivel egy adott gráf esetében a mértékek más-más csúcsokat fognak fontosnak mondani, a felhasználó feladata eldönteni, hogy melyik centralitás írja le jobban az adott modellt.
- A leíró statisztikáknak általában nem önmagukban van jelentőségük, hanem más gráfokkal összehasonlítva lehet következtetést levonni belőlük.

Hálózati terjedési modellek

Definíció (Kempe, Kleinberg, Tardos 2003)


Befolyásterjedési probléma (IM): Adott D diffúziós mechanizmus, egy G gráf és egy k pozitív egész. A feladat megtalálni a hálózat k legbefolyásosabb csúcsát, amelyek aktiválásával a legnagyobb terjedést tudjuk elérni.

- A probléma NP-nehéz, így nem létezik rá hatékony algoritmus.
- Általános feltevés szerint a központi csúcsok jó terjesztő képességekkel rendelkeznek.
- A centralitásmutatók mellett számos heurisztika létezik a probléma megoldására, de ez egy jelenleg is igen intenzíven kutatott terület.

Rogers (1962) öt csoportra osztotta az egyéneket az innovációhoz való viszonyulásuk alapján.

- Innovátorok (geek-ek)
- Korai elfogadók (vizionáriusok)
- Korai többség (pragmatikusak)
- Kései elfogadók (konzervatívok)
- Lemaradók (szkeptikusak)

Az adoptálás menete



Granovetter (1978) "Threshold Models of Collective Behavior"

- Egy tüntetésen 100-an vesznek részt. Egyikük zavargásba kezd. Minden tüntetőnek van egy küszöbértéke - ha ennél több tüntető zavarog, akkor ő is erőszakossá válik.
- Vizsgáljunk meg két küszöbérték eloszlást: $(0, 1, 2, 3, \dots, 99)$ és $(0, 2, 2, 3, \dots, 99)$.
- Az elsőben mindenki erőszakossá válik a másodikban a zavargó magára marad.

Lehetséges csúcs-állapotok

- Fertőzhető (inaktív)
- Fertőzött (aktív)
- Gyógyult (immunis)

Modell-típusok

- SI** Egy csúcs vagy fertőzhető, vagy fertőzött (példa lehet egy alapvető innováció, mint a mobiltelefon, vagy az internet)
- SIS** Egy aktív csúcs inaktívvá válhat (egy híresztelés, vagy egy app, amiről le lehet iratkozni)
- SIR** Csúcsok időleges, vagy végleges immunitást szerezhetnek (vírus, addikció)

Lineáris küszöb (linear threshold)

Egy csúcs akkor válik aktívvá, ha sok ismerőse aktív.


- Választunk egy véletlen $b \in [0, 1]$ küszöböt minden csúcsnak.
- Minden e élhez hozzárendelünk egy $w_e \in [0, 1]$ súlyt. Minden csúcsra a beérkező élek súlyát 1-re normáljuk.
- Egy csúcs aktívvá válik, ha az aktív ismerősök felől érkező élek súlya meghaladja a csúcs küszöbértékét.

Független kaszkád (independent cascade)

Minden frissen aktívvá vált csúcsnak egyetlen esélye van, hogy megfertőzze a szomszédait.

- Minden e élhez rendelünk egy $w_e \in [0.01, 0.1]$ terjedési valószínűséget, amely megmutatja, hogy mekkora eséllyel fertőzi meg az él kezdőpontja az él végpontját.
- Amikor egy csúcs aktívvá válik, megpróbálja megfertőzni a szomszédait. A folyamatnak akkor van vége, ha nincs több frissen megfertőződött csúcs.

Példa



Köszönöm a figyelmet!